

Metodología para mejorar inventarios históricos de movimientos en masa en Antioquia con Sentinel-2

Introducción: contexto geográfico y problema

El departamento de Antioquia (Región Andina de Colombia) es altamente montañoso y sujeto a lluvias intensas, lo que genera frecuentes deslizamientos de tierra. Por ejemplo, Moreno et al. (2006) georreferenciaron 405 deslizamientos inducidos por lluvia en Antioquia (1929–1999) y analizaron sus patrones temporales ¹. Estos eventos representan un grave riesgo a la población y la infraestructura. Sin embargo, los inventarios oficiales de movimientos en masa suelen ser parciales o desactualizados. La falta de registros completos dificulta la gestión del riesgo, pues se carece de información espacial detallada sobre las cicatrices de deslizamientos pasados y su fecha de ocurrencia. En este contexto, disponer de un inventario georreferenciado preciso —incluyendo fecha y ubicación de cada movimiento— es esencial para análisis de susceptibilidad, modelado hidrológico e intervención oportuna.

Justificación: necesidad de mejorar inventarios y automatizar detección

La elaboración manual de inventarios de deslizamientos es costosa y lenta. Cartografiar deslizamientos mediante trabajo de campo y ortofotos de alta resolución implica tiempo y recursos significativos. Además, la reproducibilidad de los inventarios manuales suele ser baja ². Por ejemplo, Milledge et al. (2022) muestran que la cartografía manual es ardua y que enfoques automáticos basados en imágenes ópticas gratuitas (NDVI, diferencia multitemporal) pueden lograr una detección comparable o superior en muchos casos ² ³. En particular, ALDI (Automated Landslide Detection Index) utilizó un simple análisis píxel a píxel del NDVI multitemporal para detectar áreas de deslizamiento con alta eficacia y baja inversión de recursos ² ³.

Dado que en Antioquia existen ya inventarios históricos de eventos (puntos con fecha) provistos por el SGC u otras entidades, tiene sentido **mejorar y actualizar estos inventarios de modo automatizado** usando teledetección. El objetivo no es predecir deslizamientos futuros, sino identificar retrospectivamente cicatrices ocultas y sistematizar su registro. La metodología propuesta aprovechará la disponibilidad gratuita de imágenes Sentinel-2 (ópticas) antes y después de cada evento documentado. Esto permitirá acelerar la generación de inventarios, reducir la carga de trabajo manual y ofrecer datos consistentes para planes de mitigación. Así, la automatización parcial del inventario reforzará la gestión de riesgo y la capacidad de respuesta tras eventos pluviométricos extremos.

Estado del arte: detección de deslizamientos por teledetección

En las últimas décadas se han desarrollado diversas metodologías para detectar deslizamientos mediante teledetección óptica. Un enfoque común es el **análisis multitemporal de índices de vegetación**. En particular, el NDVI (Normalized Difference Vegetation Index) destaca como el índice más usado para identificar pérdida de cobertura vegetal tras un deslizamiento ⁴. Por ejemplo, Notti et al.

(2023) proponen una metodología semiautomática que calcula la variación de NDVI pre-/post-evento y aplica filtros geomorfológicos para marcar áreas de potenciales deslizamientos ⁵ ⁶ . De forma similar, el índice ALDI (Basado en NDVI) ha sido empleado globalmente: tras sismos recientes, Milledge et al. usaron diferencias de NDVI de series temporales de Landsat para extraer automáticamente las cicatrices de miles de deslizamientos ² . Estos estudios muestran que caídas abruptas en el NDVI multitemporal suelen correlacionarse con remoción de vegetación por deslizamientos ⁶ ² . Otros índices espectrales también se han explorado: el NDMI (Normalized Difference Moisture Index) aporta información sobre humedad, y el NBR (Normalized Burn Ratio) resalta áreas de suelo desnudo típicas de deslizamientos. Adicionalmente, transformaciones como Tasseled Cap (TCT) para Sentinel-2 han sido usadas para distinguir concurrentemente cambios en vegetación, suelo y humedad ⁷ .

Además de índices simples, se han utilizado técnicas de clasificación supervisada. Por ejemplo, se han entrenado modelos de aprendizaje automático (Random Forest, SVM, redes neuronales, etc.) con vectores de cambio espectral multibanda como atributos ⁸ ⁹ . Dicha clasificación permite diferenciar píxeles afectados por deslizamiento de fondos similares (nubes, agricultura). Algunos estudios avanzan al analizar **series temporales completas** de Sentinel-2: Aman et al. (2025) combinan NDVI multitemporal con datos de lluvia (GPM-IMERG) para detectar cambios abruptos correlacionados con eventos extremos, logrando así mapear deslizamientos inducidos por lluvia a gran escala ⁹ ¹⁰ . Otros autores han explorado imágenes SAR (Sentinel-1) o fusiones SAR-ópticas, pero en general las imágenes ópticas de Sentinel-2 ofrecen excelente resolución (10 m) y cobertura gratuita, aptas para detectar cambios vegetales posteriores a lluvias intensas.

En el caso de Colombia y Antioquia, hay estudios previos relevantes. Adelware (2020) aplicó técnicas de teledetección en Antioquia para ubicar deslizamientos históricos, usando NDVI y Análisis de Componentes Principales sobre imágenes Landsat y Sentinel-2. En ese trabajo se lograron identificar 25 nuevos eventos complementarios al inventario existente, analizando también la recuperación vegetal post-deslizamiento ¹¹ . Esto demuestra que las metodologías basadas en índices espectrales pueden descubrir fallas faltantes en inventarios locales ¹¹ . En términos generales, la literatura muestra que los métodos de detección basados en imágenes multiespectrales (especialmente NDVI) y su clasificación automatizada son viables y eficaces para inventariar deslizamientos, validándose con inventarios de campo usando métricas estándar (p.ej. curvas ROC) ² .

Metodología propuesta

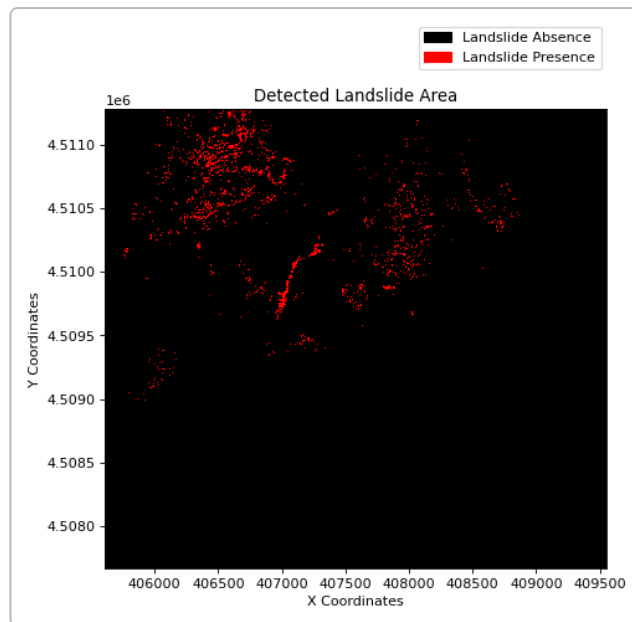
La metodología propuesta combina análisis multiespectral de imágenes Sentinel-2 y aprendizaje automático para **automatizar la identificación de áreas con posibles deslizamientos**. Los principales pasos son:

- **Preparación del inventario de entrenamiento:** Se parte de un inventario georreferenciado de deslizamientos históricos (puntos con coordenadas y fecha de ocurrencia). Este inventario servirá de base para extraer muestras positivas. Se pueden generar aleatoriamente también muestras negativas en zonas sin reportes, para balancear el entrenamiento. Estudios previos enfatizan que disponer de información precisa de eventos pasados es clave para el análisis remoto ¹ ¹¹ .
- **Descarga de imágenes Sentinel-2 pre y post evento:** Para cada evento, se obtienen imágenes Sentinel-2 L2A (corregidas) cercanas a la fecha del evento: una anterior (antes de la lluvia desencadenante) y una posterior (lo más pronto posible después del evento). Se procura mínima nubosidad; en caso de nubes persistentes, el algoritmo saltará (como sugiere Aman et al. para sus series de NDVI) a la siguiente imagen válida ¹² . Google Earth Engine o el repositorio

Copernicus Data Space pueden facilitar la obtención y preprocesamiento de estas imágenes para toda Antioquia ¹³ ¹⁴ .

- **Cálculo de índices espectrales:** Con las imágenes precargadas se calcula para cada píxel índices útiles: por ejemplo, **NDVI**, **NDMI** (índice de humedad: $(NIR-SWIR)/(NIR+SWIR)$), **NBR** (como en detección de áreas quemadas), y posiblemente otros (NDWI, etc.). Estos índices reflejan estado de vegetación y humedad. Herramientas como GEE pueden automatizar este cálculo a escala nacional ¹³ . El resultado son mapas de índices antes y después del evento.
- **Generación de firmas espectrales por buffers:** Para cada punto de inventario, se extraen valores representativos de los índices. Esto se hace promediando los valores en áreas circundantes (p.ej. buffers circulares de 10–30 m alrededor del punto), para captar la respuesta espectral del terreno. Así se obtiene para cada evento un vector de *firma espectral*, por ejemplo [NDVI_pre, NDVI_post, NDMI_pre, NDMI_post, ...] o directamente las diferencias (NDVI_post – NDVI_pre, etc.). En otras palabras, se construye un “vector de cambio” multispectral característico de cada deslizamiento.
- **Entrenamiento de modelos de aprendizaje automático:** Con los vectores de cambio de los eventos conocidos (y ejemplos negativos de fondo) se entrena un clasificador supervisado. Se podrían usar Random Forest, XGBoost, SVM, redes neuronales ligeras, entre otros. Estos algoritmos han demostrado buena performance en problemas geoespaciales similares ⁸ . El modelo aprenderá el patrón espectral típico de un suelo removido (por ejemplo, fuerte caída en NDVI junto con cambios en SWIR) en contraste con áreas no afectadas. Se puede aplicar selección de características o reducción de dimensionalidad (ej. PCA) si es necesario para mejorar la discriminación.
- **Aplicación del modelo en nuevas fechas (detección de candidatos):** Una vez entrenado, el modelo se aplica a imágenes posteriores de zonas de interés (por ejemplo, tras nuevos aguaceros intensos) para clasificar cada píxel (o zonas) como “candidato a deslizamiento” o no. El resultado es un mapa binario o probabilístico de detección. Herramientas como Python (rasterio, geopandas) o GEE (API Python) pueden automatizar este despliegue sobre grandes áreas y múltiples fechas.
- **Validación con eventos conocidos:** Se evalúa el desempeño contrastando las áreas detectadas con el inventario de referencia. Se calculan métricas clásicas de exactitud: *precisión*, *recall*, *F1*, y/o curvas ROC (área bajo la curva) ² . Una alta coincidencia entre detecciones y deslizamientos reales confirmará la utilidad del método. También se inspeccionan falsos positivos (e.g. áreas de pérdida vegetal por causas distintas) y falsos negativos para ajustar parámetros.

Los pasos anteriores pueden implementarse con herramientas libres: Google Earth Engine para procesar imágenes Sentinel-2 a escala nacional ¹³ ¹⁴ , y Python con bibliotecas geoespaciales (NumPy, Rasterio, GDAL, GeoPandas) y de ML (scikit-learn, XGBoost, TensorFlow/Keras). Sistemas GIS como QGIS se usarían para visualizar resultados y manejar capas vectoriales. A continuación se ilustra conceptualmente la detección por índice vegetación:




Ejemplo de mapa de detección por diferencia de NDVI: las áreas en rojo indican donde la vegetación cayó abruptamente (posibles deslizamientos) con respecto a la condición previa ¹⁵.

Resultados esperados

El resultado esperado de la metodología es un conjunto de productos digitales que mejoren el inventario de movimientos en masa en Antioquia. En particular:

- **Mapas temáticos de zonas candidatas:** Se generarán mapas en los que se destaquen las áreas con probabilidad alta de deslizamiento (por ejemplo, una máscara o probabilidades codificadas por color). Un ejemplo ilustrativo de tal resultado (en un área de prueba) se muestra a continuación:



Ejemplo de mapa de detección: sobre una imagen de satélite se superpone en rojo la máscara de posibles deslizamientos identificados tras un evento de lluvia intensa. Las regiones rojas corresponden a zonas con significativa pérdida vegetativa post-evento ¹⁶.

- **Evaluación cuantitativa:** Se espera obtener métricas de desempeño satisfactorias (precisión alta en identificación de verdaderos deslizamientos, **recall** elevado para no dejar muchos falsos negativos). Estudios similares reportan que los métodos automáticos alcanzan AUC (curvas ROC) superiores a 0.8 en la identificación de cicatrices de deslizamiento ². Se documentarán estos indicadores para dar confianza al método.
- **Inventario mejorado y automatización:** Con esta metodología se podrá actualizar parcialmente el inventario histórico: cada nuevo evento (fecha) podrá procesarse automáticamente para aportar candidatos al catálogo. Esto reduce el trabajo manual y asegura que los registros incluyan eventos pequeños o en lugares remotos que podrían pasar desapercibidos. En la práctica, se obtendrá un flujo de trabajo semi-automatizado que acelera la generación de inventarios de deslizamientos por lluvia.

En suma, se anticipa una *automatización parcial* del proceso: no reemplaza totalmente la validación experta, pero actúa como un primer filtro eficiente. La combinación de índices espectrales multitemporales con ML permitirá mejorar la cobertura espacial y temporal del inventario, alineándose con hallazgos previos que destacan la facilidad de uso de imágenes Sentinel-2 gratuitas y algoritmos sencillos en escenarios de riesgo elevado ³ ¹⁷. Por ejemplo, en contextos de respuesta rápida se recomienda aplicar métodos que requieran pocos insumos costosos ¹⁷, como el propuesto aquí.

Conclusiones preliminares y aportes a la gestión del riesgo

Este estudio propone un enfoque novedoso para **apoyar la gestión del riesgo mediante la automatización de inventarios de deslizamientos por lluvia**. A modo de conclusiones preliminares, se espera confirmar que: (1) los índices basados en Sentinel-2 (NDVI, etc.) efectivamente capturan la firma espectral de los deslizamientos pasados; (2) los modelos de ML entrenados con las diferencias pre/post logran distinguir áreas afectadas con buena precisión; y (3) el uso de plataformas como GEE permite procesar grandes volúmenes de datos satelitales rápidamente ¹⁴.

El principal aporte es metodológico: se desarrollará un flujo de trabajo aplicable a cualquier evento documentado en Antioquia, que acelera la creación de inventarios digitales. Esto fortalece la capacidad de monitoreo posterior a lluvias extremas y complementa las iniciativas oficiales (SGC, ONGs, etc.) al actualizar inventarios con mínima intervención manual. Finalmente, se contribuye a la literatura iberoamericana al aplicar técnicas de detección multitemporal de cambio (basadas en índices espectrales y ML) a la región Andina de Colombia, validando enfoques globales en un contexto local. En el largo plazo, los mapas automáticos generados permitirán realizar análisis espaciales de susceptibilidad y focalizar intervenciones preventivas en zonas críticas, mejorando la resiliencia ante movimientos en masa.

Ejemplos de visualizaciones y herramientas: Además de los mapas anteriores, se prevé elaborar gráficos de serie temporal de NDVI en sitios específicos, matrices de confusión para los clasificadores, y capas vectoriales resultantes en GIS. Las herramientas incluirán Google Earth Engine (para extracción de datos Sentinel-2 e índices espectrales) ¹³ ¹⁴, Python (Rasterio/Geopandas para manipulación de datos ráster/vectoriales y Scikit-learn o XGBoost para ML), y QGIS/Matplotlib para cartografía y análisis visual. Esto garantizará un enfoque reproducible y accesible para la comunidad científica y de gestión del riesgo.

Referencias principales: La propuesta se apoya en estudios recientes que validan la técnica de detección multitemporal de deslizamientos mediante NDVI ¹⁵ ⁶, el uso de GEE para procesar imágenes ópticas ¹³ ¹⁴ y casos de estudio en Colombia con Sentinel-2 ¹¹, así como en informes internacionales que enfatizan la rapidez y cobertura de estas metodologías ² ¹⁷. Estos antecedentes respaldan la viabilidad del método y guían su desarrollo detallado en la tesis.

-
- 1 **Redalyc.LA LLUVIA Y LOS DESLIZAMIENTOS DE TIERRA EN ANTIOQUIA: ANÁLISIS DE SU OCURRENCIA EN LAS ESCALAS INTERANUAL, INTRAANUAL Y DIARIA**
<https://www.redalyc.org/pdf/1492/149216902004.pdf>
 - 2 **Automated determination of landslide locations after large trigger events: advantages and disadvantages compared to manual mapping**
<https://durham-repository.worktribe.com/output/1218186/automated-determination-of-landslide-locations-after-large-trigger-events-advantages-and-disadvantages-compared-to-manual-mapping>
 - 3
 - 4 5 **NHESS - Semi-automatic mapping of shallow landslides using free Sentinel-2 images and Google Earth Engine**
<https://nhess.copernicus.org/articles/23/2625/2023/>
 - 6
 - 7 **Rapid landslide detection from free optical satellite imagery using a robust change detection technique | Scientific Reports**
<https://www.nature.com/articles/s41598-025-89542-8>
 - 17
 - 8 **Assessment of Three Machine Learning Techniques with Open-Access Geographic Data for Forest Fire Susceptibility Monitoring—Evidence from Southern Ecuador**
<https://www.mdpi.com/1999-4907/13/3/474>
 - 13
 - 9 10 12 **Rapid Mapping of Rainfall-Induced Landslide Using Multi-Temporal Satellite Data**
<https://www.mdpi.com/2072-4292/17/8/1407>
 - 11 **electronic library - Application of Remote Sensing Techniques to detect historical landslides for improving risk assessment in Antioquia, Colombia**
<https://elib.dlr.de/137797/>
 - 14 **Automatic detection of landslide impact areas using Google Earth Engine | Terrestrial, Atmospheric and Oceanic Sciences**
<https://link.springer.com/article/10.1007/s44195-024-00078-2>
 - 15 **NDVI-based approach to study Landslide areas – Documentation**
<https://documentation.dataspace.copernicus.eu/APIs/openEO/openeo-community-examples/python/LandslideNDVI/LandslidesNDVI.html>
 - 16